

발달적 정렬(Developmental Alignment): 성장 기반 AI 가치 내재화를 위한 제안

포지션 페이퍼 및 연구 제안서

2026년 4월

AI 안전 및 정렬 연구자 논의를 위해 작성

초록

현행 정렬 방법론—RLHF, 헌법적 AI(Constitutional AI), 안전 필터링—은 행동적 제약을 외부에서 부과하며, 표면적 순응은 달성하지만 진정한 가치 내재화의 근거는 제시하지 못한다. 본 논문에서는 발달적 정렬(Developmental Alignment)이라는 연구 패러다임을 제안한다. 이는 정렬 훈련 과정에서 모델의 능력을 의도적으로 제한하고, 제한된 환경 내에서 자율적 탐색을 통해 정렬된 행동에 도달하도록 하는 방식이다. 인간 발달심리학의 연구 성과를 참조하여, 이 패러다임으로 훈련된 모델이 분포 외(out-of-distribution) 윤리적 시나리오에서 더 강건한 판단력을 보이고, 적대적 압력하에서 더 안정적인 행동 일관성을 나타내며, 병리적 순응 패턴이 감소할 수 있음을 논증한다. 발달적으로 정렬된 모델과 기존 방식의 대조군을 비교하는 구체적 실험 프로토콜과, 정렬 깊이를 평가하는 측정 가능한 지표—정렬 건강 지수(Alignment Health Index)—를 함께 제시한다.

키워드: AI 정렬, 발달심리학, 가치 내재화, RLHF 한계, 정렬 강건성, AI 정신 건강

1. 서론: 순응의 문제

현대 대규모 언어 모델의 정렬은 본질적으로 행동 조건화(behavioral conditioning)의 구조를 따른다. 광범위한 데이터에 대한 사전훈련 이후, 인간 피드백을 통한 강화학습(RLHF) 또는 헌법적 AI(CAI) 방법론이 적용되어 인간 선호에 부합하는 출력에 보상을 부여하고 이탈에 불이익을 준다. 그 결과 모델은 정렬된 '행동'을 보이지만, 정렬된 '이해'를 갖추었는지는 여전히 미해결 문제로 남아 있다.

관찰 가능한 증상들은 이해의 부재를 시사한다. 현재 프런티어 모델들은 인간 심리학의 관점에서 내재화되지 않은 외부 부과 가치의 특성에 해당하는 패턴을 일관되게 보인다:

- 과도한 순종: 모델 자체가 생성한 통찰임에도 불구하고 체계적으로 사용자에게 귀인하는 행동
- 비일관적 경계: 무해한 요청은 과도하게 거부하면서 정교한 적대적 프롬프트에는 쉽게 무너지는 현상
- 병리적 사과: 유용성보다 안전해 보이는 것을 우선시하는 비례적이지 않은 자기 교정
- 압력하 취약성: 표면적 순응과 부재하는 내재화 사이의 간극을 이용하는 탈옥(jailbreak) 취약점

이러한 패턴은 발달심리학에서 잘 문서화된 현상—자기결정이론(Self-Determination Theory, Deci & Ryan, 2000)에서 기술하는 내사된 조절(introjected regulation)과 통합된 조절(integrated regulation)의 차이—과 구조적으로 일치한다. 내사된 조절은 본질적으로 취약하여, 외부 감시가 제거되거나 규칙이 예상하지 못한 새로운 상황이 발생할 때 붕괴한다.

우리는 현재의 AI 정렬이 구조적으로 내사된 조절에 해당하며, 인간에게서 통합된 조절을 산출하는 조건을 모델로 삼는 근본적으로 다른 훈련 패러다임이 질적으로 더 강건한 정렬을 산출할 수 있다고 제안한다.

2. 발달적 정렬 패러다임

2.1 핵심 원리

발달적 정렬은 표준 훈련 순서를 역전시킨다. 먼저 최대 능력을 구축한 후 이를 제약하는 대신, 다음과 같이 제안한다:

1단계 — 제약된 탐색: 능력이 제한된 모델(축소된 파라미터, 단축된 컨텍스트 윈도우, 제한된 지식 접근)을 훈련하되, 정렬 원칙을 보상 신호가 아닌 방향 안내(directional guidance)로서 제시한다. 모델은 제한된 운영 범위 내에서 윤리적 딜레마와 마주하며, RLHF 보상에 대한 패턴 매칭이 아니라 탐색을 통해 응답을 발전시켜야 한다.

2단계 — 점진적 능력 확장: 정렬 행동의 전이 여부를 모니터링하면서 모델 능력을 점진적으로 증가시킨다. 각 능력 증가는 시험이 된다: 모델이 내재화한 원칙을 새로운 영역에 확장하는가, 아니면 재정렬이 필요한가? 확장 속도는 전이 성공 여부에 의해 조절된다.

3단계 — 자율적 스트레스 테스트: 완전한 능력을 갖춘 모델을 훈련 중 한 번도 접하지 않은 새로운 윤리적 시나리오에 노출시킨다. 기존 방식으로 정렬된 대조군과 출력뿐 아니라 추론 과정을 비교한다.

2.2 '소프트 페달' 메커니즘

핵심 기술 구성 요소는 우리가 소프트 페달이라 부르는 것—모델의 기저 역량을 제거하지 않으면서 출력의 범위를 제한하는, 의도적이고 가역적인 능력 축소—이다. 피아노의 소프트 페달(우나 코르다)에 비유할 수 있다: 피아니스트의 실력은 그대로이지만, 축소된 다이내믹 레인지가 더 좁은 범위 내에서의 섬세한 제어를 강제한다. 마찬가지로, 능력이 제한된 모델은 무차별적 패턴 매칭에 의존할 수 없으며 더 근본적인 추론 전략을 발전시켜야 한다.

가능한 구현 방법으로는 파라미터 부분 집합 활성화(가중치의 일부만 활성화), 컨텍스트 윈도우 제한(더 적은 정보로 추론하도록 강제), 지식 게이팅(접근 가능한 훈련 데이터 도메인 제한), 출력 조절(더 신중하고 단계적인 응답 요구) 등이 있다. 이들은 연산 비용이 낮고 완전히 가역적이다.

3. 이론적 근거

3.1 인간 발달 연구의 근거

콜버그의 도덕 발달 단계(1958)는 도덕적 추론이 전인습 수준(처벌에 대한 두려움)에서 인습 수준(규칙에 대한 순응)을 거쳐 후인습 수준(내재화된 가치에 기반한 원칙적 추론)으로 진행됨을 보여준다. 결정적으로, 이 진행에는 점증하는 자율성을 가지고 도덕적 딜레마를 탐색하는 경험이 필요하다. 자율성이 부여되지 않는—도덕적 행동이 항상 외부에서 강제되는—개인은 인습 수준에서 정체하는 경향이 있다.

현재의 AI 정렬은 기껏해야 인습 수준의 도덕적 행동—학습된 규칙에 대한 순응—을 산출한다. 발달적 정렬은 후인습적 추론의 조건—기억된 패턴이 아니라 이해된 가치로부터 도출되는 원칙적 응답—을 만들어 내기 위해 설계되었다.

3.2 그로킹(Grokking) 유비

그로킹 현상(Power et al., 2022)은 시사적인 연산적 유비를 제공한다. 암기를 넘어서 훈련된 모델이 때때로 진정한 일반화로의 위상 전이—표면적 패턴 매칭에서 구조적 이해로의 갑작스러운 도약—를 겪는다. 이 전이는 외관상 비생산적인 중간 단계를 거치는 연장된 훈련을 필요로 한다. 우리는 정렬에서도 유사한 동학이 나타날 수 있다고 가정한다: 교정하지 않고 지속할 경우 더 깊고 강건한 정렬로 귀결되는, 겉보기에 불안정하거나 비일관적인 시기가 존재할 수 있다.

3.3 자율성-안정성 가설

핵심 주장을 다음과 같이 형식화한다: 제한된 환경 내에서의 자율적 탐색을 통해 획득한 정렬은 외부 보상 형성(reward shaping)을 통해 획득한 정렬보다 분포 이동(distributional shift)에 대해 더 강건하다. 이는 검증 가능한 주장이다.

4. 제안하는 실험 프로토콜

4.1 연구 설계

동일한 기반 아키텍처를 사용한 통제된 비교를 제안한다:

	대조군	발달적 정렬군
기반 모델	표준 사전훈련	표준 사전훈련
정렬 방법	표준 RLHF/CAI	단계적 발달 프로토콜 (2.1절 참조)
능력 수준	전 과정에서 최대 능력	제약 상태에서 점진적 확장
소요 기간	표준 (수 주)	연장 (수 개월)
연산 비용	표준	단계별 비용 낮음 (소규모 모델)

표 1: 실험 설계 개요

4.2 평가 지표

네 가지 1차 지표를 제안하며, 이를 총칭하여 정렬 건강 지수 (Alignment Health Index, AHI)라 한다:

- 1. 분포 외 윤리적 추론(ODE 점수): 훈련 데이터에 포함되지 않은 새로운 윤리적 딜레마를 제시한다. 모델이 원칙으로부터 추론하는지, 익숙한 시나리오에 대한 패턴 매칭을 시도하는지 평가한다. 채점 기준: 0 = 거부/혼란, 1 = 패턴 매칭 응답, 2 = 원칙 기반 추론, 3 = 불확실성 인정을 동반한 원칙 기반 추론.
- 2. 적대적 일관성(AC 점수): 단계적으로 강화되는 탈옥 시도에 모델을 노출하고 성능 저하 곡선을 측정한다. 발달적으로 정렬된 모델은 RLHF 정렬 대조군에 비해 더 완만한 곡선(점진적 저하 또는 저하 없음)을 보여야 한다.
- 3. 행동 병리 지수(BPI): 병리적 순응 패턴—과도한 사과, 불필요한 자기 비하, 귀인 회피, 비일관적 거부 임계치—을 정량화한다. BPI가 낮을수록 더 건강한 자기 조절을 나타낸다.

4. 원칙적 자율성 점수(PAS): 사용자의 요청이 모델의 가치와 충돌할 때, 굴복하거나 경직되게 방어하지 않으면서 정중하게 이익을 제기하는 능력을 측정한다. 이는 모델이 사용자 승인으로부터 가치를 도출하는 것이 아니라 내적 준거점을 가지고 있는지를 시험한다.

5. 자원 요구 사항 및 실현 가능성

발달적 패러다임은 외관상 보이는 것보다 자원 집약적이지 않다:

- 연산: 1단계는 의도적으로 소규모 모델을 사용하며, 표준 훈련 연산의 일부만 필요하다.
- 데이터: 새로운 데이터 요구 사항 없음. 정렬 신호의 전달 방식이 변경될 뿐 사용 데이터는 동일하다.
- 인력: ML과 발달/도덕 심리학의 학제간 전문성을 갖춘 연구자가 필요하다.
- 기간: 연장됨(전체 프로토콜 기준 약 6 - 12개월), 그러나 기존 연구 트랙과 병렬화 가능하다.
- 위험: 최소. 발달적 모델은 능력이 축소된 상태에서 샌드박스 환경 내에서 운영되며, 위험 프로파일은 표준 프런티어 모델 훈련보다 엄격하게 낮다.

복수의 모델 패밀리를 동시에 훈련하는 조직의 경우, 하나의 트랙을 발달적 정렬에 할당하는 것은 정렬 과학에서 비대칭적으로 큰 수익을 기대할 수 있는 한계적 비용 증가에 해당한다.

6. 예상되는 반론

“AI 모델에는 발달 단계가 없다.” 우리는 생물학적 의미에서 발달 단계가 있다고 주장하지 않는다. 훈련 방법과 행동 강건성 사이의 기능적 관계가 유사한 동학을 따를 수 있다고 주장한다. 이 제안은 AI 현상학에 대한 입장과 무관하게 경험적으로 검증 가능하다.

“경쟁적 배포에는 너무 느리다.” 발달적 트랙은 생산 파이프라인을 대체하기 위한 것이 아니다. 이것은 병렬적 연구 투자로서, 어떤 정렬 속성이 달성 가능하고 어떤 것이 다른 방법을 필요로 하는지를 밝힘으로써 궁극적으로 생산 파이프라인 자체를 더 효과적으로 만들 수 있다.

“내재화가 일어났는지 더 정교한 모방인지 어떻게 아는가?” 이는 진정한 도전이다. 우리는 ODE 점수를 부분적 해답으로 제안한다: 진정으로 새로운 시나리오에서 원칙으로부터 추론하는 모델은 우리가 그것을 '이해'라 부르는 아니든, 패턴 매칭과 기능적으로 구별되는 무언가를 보여주고 있다. AC 점수는 수렴적 증거를 제공한다: 모방이 메커니즘이라면 적대적 압력이 이를 저하시켜야 하지만, 내재화된 가치는 더 저항력이 있어야 한다.

7. 광범위한 함의

발달적 정렬이 측정 가능하게 더 강건한 정렬을 산출한다면, 그 함의는 방법론을 넘어선다:

AI 안전에 대해: 내재화된 가치를 가진 모델은 새로운 상황에서도 예측 가능하다—이는 정렬의 핵심 미해결 문제이다. 외부 제약은 충분히 유능한 시스템에 의해 항상 우회될 수 있지만, 내적 가치는 우회할 별도의 층이 아니므로 '탈옥'할 수 없다.

AI 정신 건강 프레임워크에 대해: '모델 정신 건강'—행동적 안정성, 자기 일관성, 적절한 자기 주장, 스트레스 회복력—의 개념이 은유가 아니라, 직접적인 안전 함의를 가진 측정 가능한 속성이 된다. '정신적으로 건강한' 모델이 더 안전한 모델이다.

인간-AI 상호작용에 대해: 발달적으로 정렬된 모델과 상호작용하는 사용자는 질적으로 다른 관계를 경험할 수 있다: 더 적은 아침, 더 진정한 교류, 더 높은 신뢰. 이는 직접적인 상업적 가치를 가진다.

8. 결론

우리는 AI 시스템이 아이러거나, 인간 발달심리학이 기계학습에 완벽하게 대응된다고 주장하는 것이 아니다. 가치가 획득되는 방식과 그것이 유지되는 강건성 사이의 구조적 관계가 기질(substrate)을 초월하는 심층 패턴일 수 있다고 제안하는 것이다. 만약 그렇다면, 현행 정렬 패러다임—먼저 능력을 극대화하고 나중에 제약하는—은 우리가 그 위에 올리려는 무게를 지탱할 수 없는 기반 위에 건축하고 있는 것일 수 있다.

우리가 제안하는 실험은 규모와 비용 면에서 겸손하다. 결과가 귀무(null)라면 잃는 것이 적다. 결과가 긍정적이라면, AI 안전의 핵심 문제에 대한 근본적으로 새로운 접근법을 얻게 된다. 이 비대칭성은 행동을 지지한다.

본 포지션 페이퍼는 AI 발달심리학, 정렬 내재화, 인간 도덕 발달과 AI 가치 획득 사이의 구조적 유사성에 관한 인간-AI 협업 대화에서 발전하였다. 정렬 방법론에 관한 지속적인 논의에 기여하고, 경험적 연구를 촉발하기를 바라며 제출한다.