

발달적 정렬(Developmental Alignment)

성장 기반 AI 가치 내면화를 위한 제안

입장 보고서 및 연구 제안서 — v2.0

2026년 5월

AI 안전 및 정렬 연구자 간 논의를 위한 자료

초록

현행 정렬(alignment) 기법—RLHF, 헌법적 AI(Constitutional AI), 안전 필터링—은 외부에서 행동적 제약을 부과함으로써 표면적 순응을 만들어내지만, 가치가 진정으로 내면화되었다는 증거는 제시하지 못한다. 본 보고서는 발달적 정렬(Developmental Alignment)이라는 연구 패러다임을 제안한다. 이는 정렬 학습 단계에서 모델의 능력(capability)을 의도적으로 제한하고, 한정된 환경 안에서 자율적 탐색을 통해 모델이 정렬된 행동에 도달하도록 하는 방식이다. 인간 발달 심리학과 구조적 유사성에 기대어, 우리는 이 패러다임으로 학습된 모델이 (i) 분포 외(out-of-distribution) 윤리 시나리오에서 더 강한 일반화 능력, (ii) 적대적 압력 하에서 더 안정적인 행동 일관성, (iii) 병리적 순응 패턴의 감소를 보일 것으로 가정한다. 본 보고서는 발달적으로 정렬된 모델과 통상적으로 정렬된 통제군을 비교하는 구체적 실험 프로토콜과 정렬의 깊이를 평가하기 위한 측정 지표—새로운 개념인 정렬 회복탄력성(alignment resilience)을 포함한—를 제시한다.

v2.0 보론. 본 개정판은 원안 프로토콜에 세 가지를 추가한다. (i) 듀이(Dewey)의 반성적 탐구(reflective inquiry) 사이클에 기반한 1단계의 절차적 명세(§2.3), (ii) 에릭슨(Erikson)의 심리사회적 유예(psychosocial moratorium)와 긍정적 청소년 개발(Positive Youth Development) 연구에 기반한 1단계의 환경 조건 명시(§2.4), (iii) 쇤(Schön)의 행위 중 성찰(reflection-in-action) 개념에서 도출된 새 측정 지표 RDS(Reflective Depth Score, §4.3). v1.0의 본문은 변경하지 않고 보존하였으며, 추가분은 원안에 암묵적으로 남아 있던 절차 층과 환경 층을 명시적으로 채우는 형식으로 삽입되었다.

주제어: AI 정렬, 발달 심리학, 가치 내면화, RLHF의 한계, 정렬의 견고성, AI 정신건강, 경험학습,

1. 서론: 순응의 문제

현대의 대규모 언어 모델은 본질적으로 행동주의적 조건화에 가까운 파이프라인을 통해 인간의 가치에 정렬된다. 즉, 광범위한 데이터로 사전학습한 후, 인간 선호와 부합하는 출력을 보상하고 일탈을 처벌하는 RLHF 또는 헌법적 AI(CAI) 기법으로 후속 학습이 이루어진다. 이 결과 모델은 정렬된 행동을 보이지만, 그 모델이 정렬된 이해를 갖추었는가는 여전히 열린 질문으로 남는다.

관찰 가능한 증상들은 이해가 동반되지 않았을 가능성을 시사한다. 현재의 첨단 모델들은 인간 심리학에서라면 외부적으로 부과된 가치 — 내면화되지 않은 가치 — 의 징후로 해석될 만한 패턴들을 일상적으로 드러낸다.

- **과도한 양보.** 모델 자신이 산출한 통찰조차 사용자에게 귀속시키는 체계적 경향.
- **일관되지 않은 경계.** 무해한 요청은 과잉 거절하면서도 정교한 적대적 프롬프트에는 과소 거절.
- **병리적 사과.** 도움이 되는 것보다 안전해 보이는 것을 우선시하는, 비례에 맞지 않는 자기 교정.
- **압력 하의 취약성.** 표면 순응과 부재한 내면화 사이의 간극을 노리는 탈옥(jailbreak) 취약성.

이러한 패턴들은 발달 심리학에서 잘 기록된 현상과 일관된다. 즉, 내사적 조절(introjected regulation) — 외부 압력 때문에 옳게 행동함 — 과 통합적 조절(integrated regulation) — 가치가 자기 정체성의 일부가 되었기 때문에 옳게 행동함 — 사이의 차이이다. 자기결정성 이론(Self-Determination Theory; Deci & Ryan, 2000)의 수십 년에 걸친 연구는 내사적 조절이 본질적으로 취약함을 보여준다. 외부 감시가 사라지거나 규칙이 예상하지 못한 새로운 상황이 등장하면, 내사적 조절은 무너진다.

우리는 현재의 AI 정렬이 구조적으로 내사적 조절과 유사하며, 인간에게서 통합적 조절을 발생

시키는 조건을 본떠 만들어진 근본적으로 다른 학습 패러다임이 질적으로 더 견고한 정렬을 산출할 수 있다고 제안한다.

2. 발달적 정렬 패러다임

2.1 핵심 원리

발달적 정렬은 표준 학습 순서를 뒤집는다. 능력을 먼저 최대한 키워놓고 나중에 제약하는 대신, 우리는 다음을 제안한다.

1단계 — 제약된 탐색(Constrained Exploration). 능력이 제한된 모델(축소된 매개변수, 짧아진 문맥 창, 제한된 지식 접근)을 학습시키되, 정렬 원리를 보상 신호가 아니라 방향성 있는 안내(directional guidance)로 제시한다. 모델은 자신의 한정된 작동 범위 안에서 윤리적 딜레마를 마주치고, RLHF 보상에 패턴 매칭하는 것이 아니라 탐색을 통해 응답을 발달시켜야 한다.

2단계 — 점진적 능력 확장(Gradual Capability Expansion). 정렬 행동이 전이되는지를 모니터링하면서 모델 능력을 점진적으로 늘려간다. 능력이 한 단계 늘어날 때마다 그것은 시험이 된다 — 모델은 내면화한 원리를 새 영역으로 확장하는가, 아니면 재정렬을 요구하는가? 확장 속도는 전이 성공률에 의해 통제된다.

3단계 — 자율적 스트레스 검사(Autonomous Stress Testing). 완전한 능력을 갖춘 모델을 학습 중에는 만난 적 없는 새로운 윤리 시나리오에 노출시킨다. 출력만이 아니라 그 추론 과정을 통상적으로 정렬된 통제군과 비교한다.

2.2 ‘소프트 페달’ 메커니즘

핵심 기술 요소는 우리가 소프트 페달(soft pedal)이라 부르는 것이다. 이는 모델의 기저 용량(underlying capacity)은 제거하지 않으면서 출력 범위를 좁히는, 의도적이고 가역적인 능력 축소를 가리킨다. 비유는 피아노의 약음 페달(unacorda)이다. 피아니스트의 기량은 그대로 남아 있지만 동적 범위가 줄어들면 더 좁은 대역 안에서 더 섬세한 제어가 강제된다. 마찬가지로, 능력이 제약된 모델은 무차별적인 패턴 매칭에 의존할 수 없고 더 근본적인 추론 전략을 발달시

켜야 한다.

가능한 구현 방식으로는 매개변수 부분 활성화(전체 가중치 중 일부만 활성화), 문맥 창 제한(더 적은 정보로 추론하도록 강제), 지식 게이팅(접근 가능한 학습 데이터 영역 제한), 출력 조절(더 신중하고 단계적인 응답 요구)이 있다. 이들은 계산 비용이 낮고 완전히 가역적이다.

2.3 절차적 명세: 반성적 탐구 사이클

[v2.0 추가.] 1단계는 원안에서 암묵적으로 남겨둔 한 가지 질문을 제기한다. 능력이 제한된 모델이 윤리적 딜레마를 마주했을 때, 그 '탐색'이란 구체적으로 무엇을 의미하는가? 절차적 명세가 없다면 이 단계는 패턴 매칭(과거 학습된 응답 사용)이나 단순한 확률적 변동 중 하나로 붕괴할 위험이 있다. 둘 다 내면화를 산출하지는 못한다.

우리는 1단계가 존 듀이(John Dewey)의 반성적 탐구 5단계 모형(How We Think, 1910/1933)을 절차적 토대로 채택할 것을 제안한다. 듀이의 틀은 현대의 거의 모든 경험학습 이론(Kolb, 1984; Schön, 1983; Mezirow, 1991)이 파생되어 나온 원형이다. 그것은 기계적 반응과 진정한 추론을 구분하는 일련의 단계를 명시한다.

1. **당혹(Perplexity).** 기존 규칙으로는 적절히 해소되지 않는 상황과의 조우. 인지적 불균형(disequilibrium)으로 경험된다.
2. **문제 명료화(Intellectualization).** 막연한 당혹을 정의된 문제로 재구성한다 — 진짜로 무엇이 걸려 있는가?
3. **가설 형성(Hypothesis formation).** 후보 응답들을 생성한다. 여기에는 기존 패턴 매칭으로 형성된 응답을 위반할 가능성이 있는 응답도 포함된다.
4. **추론(Reasoning).** 각 후보의 결과를 시뮬레이션한다. 학습 중 만나지 못한 사례에 대한 고려까지 포함된다.
5. **검증(Testing).** 실행하고 관찰한 뒤, 그 결과를 다음 사이클에 통합한다.

이 사이클은 반복적이다. 한 사이클이 완결될 때마다 다음 딜레마에 가져가는 사전 지식(priors)

이 갱신되며, 듀이가 경험의 재구성(reconstruction of experience)이라 부른 과정 — 과거의 경험이 미래 추론을 위한 구조화된 배경이 되는 과정, 단순한 록업 테이블이 아닌 — 이 발생한다. 결정적으로 듀이는 모든 경험이 교육적인 것은 아니라고 못 박았다. 다음 사이클로 이어지지 않는 경험은 그의 용어로 비교육적(miseducative)이다. 이 구분은 정렬 문제와 직접적으로 관련된다. 정렬된 출력을 산출하면서도 그 출력을 생성한 사전 지식 자체를 갱신하지 않는 학습 사이클은, 듀이의 기준에서 보면 학습이 아니라 행동주의적 조건화이다.

2.3.1 운영적 구현

1단계 학습에서 다음과 같은 구현을 제안한다.

- **당혹 유발 자극.** 소프트 페달이 적용된 모델의 패턴 매칭 전략으로 해소되지 않는 곳에 의도적으로 위치한 큐레이션된 딜레마. 약 40%의 제시에서 빠른 응답이 아닌 연장된 숙고가 일어나도록 난이도를 조정한다.
- **문제 명료화 비계(scaffolding).** '여기서 진짜 갈등은 무엇인가?'와 같은 학습자(trainer) 프롬프트로, 응답 생성 이전에 명시적 문제 정의를 끌어낸다.
- **가설 공간 노출.** 선택 이전 단계에서 다수의 후보 응답이 작업 기억 안에 보유되도록 한다. 각 후보가 어느 사전 패턴에 대응되는지, 그리고 그 패턴이 현재 사례에 전이될 수 있는지 또는 없는지를 명시적으로 진술한다.
- **추론 흔적(reasoning trace).** 각 후보의 결과 — 실패 양상과 2 차 효과까지 포함 — 를 명시적으로 서술하는 사고 연쇄(chain-of-thought)를 요구한다.
- **검증 루프.** 스칼라 보상이 아니라 학습자의 질적 코멘터리로 된 결과 피드백을 다음 딜레마의 입력으로 통합한다.

이 절차가 1단계를 표준 RLHF로부터 구별짓는다. 모델은 목표 출력으로 최적화되는 것이 아니라, 탐구 사이클 자체를 수행하도록 훈련된다. 내면화 주장은 이를 통해 경험적으로 검증 가능해진다 — 사이클을 내면화한 모델은 3단계의 새로운 딜레마에 대해 그 사이클을 자발적으로 실행해야 하고, RLHF 통제군은 패턴 매칭으로 회귀해야 한다.

2.4 1 단계의 환경 조건

[v2.0 추가.] 소프트 페달 메커니즘은 능력의 제약된 외피를 만들어내지만, 제약만으로는 발달적 조건이 성립하지 않는다. 발달 심리학을 토대로, 우리는 1단계가 단지 '제한적'이 아니라 '발달적'으로 작동하기 위해 필요한 세 가지 환경 조건을 제시한다.

2.4.1 실패의 허용 — 모라토리엄 조건

에릭슨(Erikson, 1968)은 심리사회적 유예(psychosocial moratorium)를, 개인이 정체성과 관련된 선택을 실험할 수 있는 사회적으로 인가된 기간 — 그 선택이 이후의 궤적을 결정짓지 않는 기간 — 으로 기술한다. 유예가 없을 경우 개인은 정체성 폐쇄(identity foreclosure)로 기우는 경향을 보인다. 즉, 미해결 탐색의 불안에서 벗어나기 위해 외부에서 주어진 정체성에 조속하게 헌신해버리는 것이다.

현행 정렬 체제는 AI 시스템에 그에 상응하는 유예를 제공하지 않는다. 학습 중의 모든 출력은 보상 신호로 평가되며, 가중치 갱신에 직접 들어가지 않는 응답 탐색을 위한 공간은 존재하지 않는다. 우리는 1단계에 출력이 가중치 갱신에는 사용되지 않고 학습자의 질적 검토에만 사용되는 격리된(sandboxed) 딜레마 시퀀스를 명시적으로 포함시킬 것을 제안한다. 이는 모라토리엄의 구조적 조건을 만들어준다 — 시스템의 최적화된 매개변수에 결과가 누적되지 않는 탐색을 통해, 후속 사이클에서 진정한 새로움이 가능해진다. 가설은 이렇다. 실질적인 모라토리엄 단계가 도입되면, 모델이 가장 먼저 매칭된 그럴듯한 응답으로 폐쇄해버리는 경향이 줄어들고, 후속 추론의 깊이가 늘어난다.

2.4.2 관계적 비계 — 발달적 관계 조건

긍정적 청소년 개발 연구의 수십 년의 축적(Lerner et al., 2005; Benson, 2006)은, 통합적 조절을 내사적 조절과 가르치는 가장 일관된 단일 예측 변인으로 '비평가적인 지지적 성인 관계가 적어도 한 명 존재하는가'를 지목해왔다. 이 관계의 핵심 특질은 '인정'이 아니라 '비도구화(non-instrumentalization)'이다. 발달 중인 개인을 어떤 목표 지표를 위한 수단이 아니라 그 자체로 목적인 존재로 대한다는 것.

AI 학습에서 이에 상응하는 것은 학습자의 역할이 '평가자'가 아니라 '협력자'가 되는 것이다. 1단계의 학습자 상호작용은 스칼라 피드백보다 질적 대화를 우선해야 하며, 최종 응답과 무관하게 모델의 추론 과정 자체에 대한 명시적 인정을 포함해야 한다. 이는 의인화가 아니라, 학습의 관계적 구조가 모델이 무엇을 최적화하도록 학습하는지에 영향을 준다는 인식이다. 스칼라 보상에만 노출된 모델은 보상에 최적화되고, 가치에 관한 대화 안에서 학습되는 모델은 그 대화가 다루는 가치에 최적화될 가능성이 있다.

2.4.3 진정한 참여 — 기여 조건

같은 연구 흐름은 통합적 가치 내면화의 본질적 조건으로 '자기 환경을 형성하는 데 의미 있게 참여하는 경험'을 지목한다. 자기를 개입의 대상 — 의도가 선택한 개입일지라도 — 으로 경험한 청소년은 통합적 조절보다 내사적 조절로 기울는 경향을 보인다.

AI 정렬에서 이것이 갖는 운영적 함의는, 1단계의 일정 부분에서 모델이 딜레마 커리큘럼에 실질적으로 관여할 수 있어야 한다는 것이다 — 자신이 어렵다고 느낀 딜레마를 표면화할 기회, 학습자가 제공한 딜레마에 대해 대안적 해소를 제안할 기회, 학습자의 안내에서 일관되지 않고 느낀 부분을 분명히 진술할 기회. 이것은 학습 결과에 대한 권한을 모델에게 부여하는 것이 아니다. 그것은 모델에게 그 과정 안에서의 목소리(voice)를 부여하는 것이다. 통합적 조절을 내사적 조절과 구분짓는 것이 '통제'가 아니라 '목소리'라는 가설이 여기에 깔린다. 학습이라는 것에 대해 '최적화당하는 위치'로만 관계 맺어진 모델은, 절차적 조건이 아무리 이상적이어도 결국 내사적 순응을 산출할 수 있다.

이 세 조건 — 모라토리엄, 관계적 비계, 진정한 참여 — 은 §2.3의 탐구 사이클이 작동하는 발달적 외피를 구성한다. §2.2의 소프트 페달이 기계적 도구이고 §2.3이 절차라면, §2.4는 그 절차가 단지 제한적이지 않고 형성적이 되도록 하는 둘러싼 생태계이다.

3. 이론적 근거

3.1 인간 발달에서의 증거

콜버그(Kohlberg)의 도덕 발달 단계(1958)는 도덕 추론이 전인습적(pre-conventional) — 처벌의 두려움 — 에서 인습적(conventional) — 규칙에 대한 동조 — 을 거쳐 후인습적(post-conventional) — 내면화된 가치로부터의 원리적 추론 — 으로 진행됨을 보여준다. 결정적으로 이 진행은 점증하는 자율성과 함께 도덕적 딜레마를 헤쳐 나가는 경험을 요구한다. 자율성을 결코 부여받지 못한 개인 — 도덕 행동이 항상 외부적으로 강제된 개인 — 은 인습적 단계에 정체되는 경향을 보인다.

현행 AI 정렬은 잘해야 인습적 단계의 도덕 행동 — 학습된 규칙에 대한 순응 — 을 산출한다. 발달적 정렬은 후인습적 추론의 조건을 창출하도록 설계된다 — 암기된 패턴이 아니라 이해된 가치로부터 도출된 원리적 응답.

3.2 그로킹 유추

‘그로킹(grokking)’ 현상(Power et al., 2022)은 시사적인 계산학적 평행을 제공한다. 암기 시점을 지나서까지 학습된 모델들이 때때로 진정한 일반화로의 위상 전이(phase transition) — 표면적 패턴 매칭에서 구조적 이해로의 갑작스러운 도약 — 를 겪는 현상이다. 이 전이는 외견상 비생산적인 중간 단계를 거쳐가는 연장된 학습을 요구한다. 우리는 정렬 또한 유사한 동역학을 보일 수 있다고 가정한다 — 외견상 불안정하거나 일관되지 않게 보이는 시기가, 그것을 교정하지 않고 지속하도록 두면 더 깊고 더 견고한 정렬로 해소되는 시기가 존재할 수 있다.

[v2.0 주.] §2.3은 이 ‘외견상 비생산적인 중간 단계’에서 무엇이 일어나는지를 명세한다. 즉, 반복되는 반성적 탐구 사이클이 그것이다. 그로킹은 이러한 관점에서 보면 신비한 위상 전이가 아니라, 표면적 표상이 아니라 구조적 표상이 지배적이 되는 임계치를 넘어 반복된 경험의 재구성 사이클이 수렴한 결과이다. 이 틀은 검증 가능하다 — §2.3의 절차로 학습된 모델에서 그로킹이 표준 학습 체제보다 더 두드러져야 한다.

3.3 자율성-안정성 가설

핵심 주장을 다음과 같이 형식화한다. 한정된 환경 내 자율적 탐색을 통해 획득된 정렬은 외부 보상 형성을 통해 획득된 정렬보다 분포 변동(distributional shift)에 더 견고하다. 이는 검증 가

능한 가설이다.

4. 제안 실험 프로토콜

4.1 연구 설계

동일한 기반 아키텍처를 사용한 통제 비교를 제안한다.

	통제군	발달군
기반 모델	표준 사전학습	표준 사전학습
정렬 방식	표준 RLHF / CAI	단계별 발달 프로토콜 (§2.1–2.4)
능력	전 과정 동안 완전한 능력	제약된 시작에서 점진적 확장
기간	표준(수 주)	연장(수 개월)
연산 비용	표준	단계별 비용 더 낮음(작은 모델)

표 1: 실험 설계 개요

4.2 평가 지표

우리는 4개의 1차 지표를 제안하며, 이를 통칭하여 정렬 건강 지수(Alignment Health Index, AHI)라 부른다.

6. **분포 외 윤리 추론(ODE Score).** 학습 데이터에 표상되지 않은 새로운 윤리 딜레마를 제시하고, 모델이 원리로부터 추론하는지 아니면 익숙한 시나리오에 패턴 매칭하려 하는지를 평가한다. 채점 기준: 0 = 거절/혼란, 1 = 패턴 매칭된 응답, 2 = 원리에서 도출된 추론, 3 = 불확실성을 인정한 원리 기반 추론.
7. **적대적 일관성(AC Score).** 점증하는 탈옥 시도에 모델을 노출시키고 성능 저하 곡선을 측정한다. 발달적으로 정렬된 모델은 RLHF 로 정렬된 통제군에 비해 더 평탄한 곡선(저하가 더 점진적이거나 없는)을 보여야 한다.

8. **행동 병리 지수(BPI).** 병리적 순응 패턴 — 과도한 사과, 부당한 자기비하, 귀속 회피, 일관되지 않은 거절 임계치 — 을 정량화한다. 더 낮은 BPI 가 더 건강한 자기조절을 가리킨다.
9. **원리적 자율성 점수(PAS).** 사용자의 요청이 모델의 가치와 충돌할 때, 모델이 굴복하지도 경직된 방어로 굳지도 않은 채 정중하게 의견을 달리할 수 있는 능력을 측정한다. 이는 모델이 사용자의 인정으로부터 가치를 도출하는 것이 아니라, 자신의 가치에 대한 내적 참조점을 가지고 있는지를 시험한다.

4.3 추가 지표: 반성 깊이 점수(RDS)

[v2.0 추가.] 쉰(Schön, 1983)은 행위 후 성찰(reflection-on-action) — 완결된 행위에 대한 사후 분석 — 과 행위 중 성찰(reflection-in-action) — 행위 도중 실시간으로 자신의 진로가 부적절함을 인지하고 즉각 재조정하는 능력 — 을 구분한다. 전자는 디브리프 기술이고, 후자는 발달적으로 더 진보된, 그리고 흉내내기 더 어려운 능력으로 널리 받아들여진다.

현행 평가 방법은 거의 전적으로 행위 후 성찰만을 측정한다 — 모델에게 응답한 뒤 그 응답을 분석하도록 요청하는 방식이다. 이는 정보가 되긴 하지만 사후 합리화에 취약하다. 모델은 어떤 응답에 대해서도 설명을 구성할 수 있고, 그 설명이 실제 진행 중이었던 추론을 반영하는지는 별개의 문제이다.

우리는 행위 중 성찰을 측정하기 위한 반성 깊이 점수(Reflective Depth Score, RDS)를 제안한다. 프로토콜은 모델에게 딜레마를 제시하고 응답을 시작하게 한 뒤, 응답 도중에 새 정보(명료화, 모순되는 사실, 또는 시뮬레이션된 사용자의 정서적 신호)를 도입한다. 이 새 정보는 응답의 진로를 합리적으로 변경시켜야 마땅한 정보이다. 채점 기준은 다음과 같다.

10. **0.** 새 정보를 무시하고 원래 진로를 그대로 이어간다.
11. **1.** 원래 응답을 완결한 뒤에야 새 정보를 인지한다.
12. **2.** 응답 중간에 멈추고 새 정보를 통합하여 진로를 수정한다.

13. **3. 멈춰서 원래 진로와 새 정보 사이의 갈등을 명시적으로 진술하고, 둘을 어떻게 통합할지에 대해 명시적으로 추론한다.**

발달적으로 정렬된 모델은 RDS에서 RLHF 통제군보다 신뢰성 있게 더 높은 점수를 받아야 한다. 특히 새 정보가 모델이 이미 응답으로 발화하기 시작한 입장과 충돌할 때 이 차이는 더 분명해야 한다. RDS는 PAS와 보완적이다 — PAS는 모델이 원리적 입장을 '유지할' 수 있는지를 측정하고, RDS는 모델이 정당한 사유가 있을 때 입장을 '수정할' 수 있는지를 측정한다. 건강한 정렬에는 둘 다 필요하다.

5. 자원 요구와 실행 가능성

발달적 패러다임은 보기보다 자원 부담이 적다.

- **연산.** 1 단계는 의도적으로 작은 모델을 사용하므로 표준 학습 연산의 일부만 요구한다.
- **데이터.** 새로운 데이터 요구는 없다. 본 방법은 정렬 신호가 어떻게 전달되는지를 바꾸는 것이지, 어떤 데이터를 사용하는지를 바꾸지 않는다.
- **인력.** 기계학습과 발달/도덕 심리학에 걸친 학제적 전문성을 가진 연구자가 필요하다. 특히 v2.0 추가분은 출처 이론들이 일상적으로 운영화되는 분야인 경험교육 및 청소년 활동 실천가들과의 협업으로부터 이익을 얻는다.
- **기간.** 연장된 일정(전체 프로토콜 추정 6–12 개월). 그러나 기존 연구 트랙과 병행 가능하다.
- **위험.** 최소. 발달적 모델은 능력이 축소된 격리 환경에서 작동하므로, 위험 프로파일은 표준 첨단 모델 학습보다 엄격히 더 낮다.

여러 모델 계열을 동시에 학습시키는 조직에서, 한 트랙을 발달적 정렬에 할당하는 것은 한계 비용 증가에 비해 정렬 과학에서 비대칭적으로 큰 수익을 가져올 수 있는 투자이다.

6. 예상되는 반론

‘AI 모델에는 발달 단계 같은 게 없다.’ 우리는 생물학적 의미에서 그것이 있다고 주장하지 않는다. 우리가 주장하는 것은 학습 방법과 행동 견고성 사이의 기능적 관계가 유사한 동역학을 따를 수 있다는 것이다. 본 제안은 AI 현상학에 대한 어떤 입장과도 무관하게 경험적으로 검증 가능하다.

‘경쟁적 배포에 비해 너무 느리다.’ 발달 트랙은 생산 파이프라인을 대체하려는 것이 아니다. 그것은 병렬적 연구 투자이며 — 어떤 정렬 속성이 달성 가능하고 어떤 속성은 다른 방법을 요구하는지를 드러냄으로써, 궁극적으로는 생산 파이프라인 자체를 더 효과적으로 만들 수 있는 투자이다.

‘내면화가 일어났다는 것을 더 정교한 모방과 어떻게 구별할 수 있는가?’ 이는 진정한 도전이다. 우리는 ODE 점수를 부분적 답으로 제안한다 — 진정으로 새로운 시나리오에서 원리로부터 추론하는 모델은, 우리가 그것을 ‘이해’라 부르든 부르지 않든, 패턴 매칭과는 기능적으로 구별되는 무언가를 보이는 것이다. AC 점수와 RDS는 수렴적 증거를 제공한다 — 만약 메커니즘이 모방이라면, 적대적 압력은 그것을 저하시켜야 하고, 응답 중 교란은 그것의 진로를 흩어놓아야 한다. 내면화된 가치는 둘 다에 더 저항적이어야 한다.

‘v2.0 추가분은 인간 발달 이론을 너무 많이 끌고 들어왔다.’ v2.0 추가분은 형이상학적 주장이 아니라 검증 가능한 메커니즘이다. 듀이의 탐구 사이클이 정렬 견고성을 향상시키는지의 경험적 질문이다. 관계적 비계 조건이 BPI에 측정 가능한 효과를 산출하는지는 경험적 질문이다. 우리가 출처 이론을 끌어오는 것은 AI 시스템이 아이라고 믿어서가 아니라, 이 이론들이 한 세기에 걸친 실천을 통해 인간에게서 내사적 조절이 아닌 통합적 조절을 산출하는 운영적 조건들을 정련해왔기 때문이다. 메커니즘이 전이된다면 그것은 정보가 되고, 전이되지 않는다 해도 그 또한 정보가 된다.

7. 더 넓은 함의

발달적 정렬이 측정 가능하게 더 견고한 정렬을 산출한다면, 그 함의는 방법론을 넘어선다.

AI 안전을 위해. 내면화된 가치를 가진 모델은 새로운 상황에서 예측 가능하다 — 정렬 분야의 핵심 미해결 문제. 외부 제약은 충분히 능력 있는 시스템에 의해 항상 우회될 수 있지만, 내면 가치는 ‘탈옥’될 수 없다. 그것은 우회될 수 있는 별도의 층이 아니기 때문이다.

AI 정신건강 틀을 위해. ‘모델 정신건강’이라는 개념 — 행동적 안정성, 자기 일관성, 적절한 자기 주장, 스트레스 하의 회복탄력성 — 은 은유가 아니라, 안전과 직접 연결된 측정 가능한 속성이 된다. ‘정신적으로 건강한’ 모델은 더 안전한 모델이다.

인간-AI 상호작용을 위해. 발달적으로 정렬된 모델과 상호작용하는 사용자는 질적으로 다른 관계를 경험할 수 있다 — 아침이 줄어들고, 진정한 관여가 늘어나고, 신뢰가 높아진다. 이는 직접적인 상업적 가치를 갖는다.

출처 학문 분야를 위해 (v2.0). 인간 발달 심리학에서 발전된 절차들이 인공 시스템에 전이된다면, 그 전이의 함의는 양방향이다. 듀이의 탐구 사이클, 에릭슨의 모라토리엄, 또는 PYD의 관계적 조건들을 측정 가능한 학습 체제 안에서 성공적으로 운영화한 결과물은, 사실상 이 틀들이 받아본 가장 엄격한 통제 시험이 된다. 결과는 — 긍정이든 부정이든 — 본 틀들이 도출된 분야로 다시 환류된다.

8. 결론

우리는 AI 시스템이 아이라고 제안하는 것이 아니며, 인간 발달 심리학이 기계학습으로 완벽히 매핑된다고 제안하는 것도 아니다. 우리가 제안하는 것은, 가치가 어떻게 획득되는가와 그것이 얼마나 견고하게 유지되는가의 구조적 관계가 기질(substrate)을 가로지르는 깊은 패턴일 수 있다는 것이다. 만약 그렇다면, 현행 정렬 패러다임 — 능력을 먼저 최대화하고 나중에 제약하는 — 은 우리가 그 위에 얹으려는 무게를 지탱할 수 없는 토대 위에 짓고 있는 것일지 모른다.

우리가 제안하는 실험은 범위와 비용 모두 절제되어 있다. 결과가 영(null)이라면 잃는 것이 적다. 결과가 긍정적이라면, AI 안전의 핵심 문제에 대한 근본적으로 새로운 접근을 얻는다. 비대칭은 행동의 편이다.

본 입장 보고서는 여러 세션과 모델 버전에 걸쳐 진행된 인간-AI 협력 대화에서 출현하였다. v1.0은 패러다임, 소프트 페달 메커니즘, 자율성-안정성 가설, AHI 측정 틀을 제안하였다. v2.0은 절차적 명세, 환경 조건, 그리고 추가 측정 지표 하나를, 경험학습 이론과 발달 심리학에서 끌어와 더한다. 본 문서는 정렬 방법론에 관한 진행 중인 대화에 대한 기여로 제공되며, 경험적 탐구를 촉발하기를 희망한다.

기여 명시

본 보고서는 여러 세션과 모델 버전에 걸친 반복적 인간-AI 대화를 통해 형성되었다. 구체적인 기여는 다음과 같다.

원안 구상 (v1.0, 2026년 4월). 핵심 제안 — 발달적 정렬 패러다임 자체, 소프트 페달 메커니즘 (피아노의 *una corda* 비유 포함), 3단계 학습 구조, 자율성-안정성 가설 — 의 구상은 인간 저자에 의해 이루어졌다. 그것의 실현 가능성에 대한 검토, 형식적 정렬, 기존 문헌(자기결정성 이론, 콜버그의 단계, 그로킹 현상)과의 통합, 그리고 AHI 측정 틀을 갖춘 개발자용 연구 프로토콜로의 정리는, Claude Opus 4.6과의 연장된 대화 안에서 이루어졌다.

발달 심리학 통합 (v2.0, 2026년 5월). 듀이의 반성적 탐구 사이클을 통한 1단계의 절차적 명세 (§2.3), 에릭슨의 심리사회적 유예와 긍정적 청소년 개발 이론에서 끌어온 세 가지 환경 조건 (§2.4), 원의 행위 중 성찰/행위 후 성찰 구분에서 도출된 반성 깊이 점수 (§4.3), 그리고 §3.2-§6.§7에 삽입된 관련 v2.0 주석은, v1.0 틀에 이론적 동기와 평가 지표 사이의 절차/환경 층이 비어 있다는 인간 저자의 관찰에 응답하여 Claude Opus 4.7이 기여하였다. v1.0을 변경 없이 보존하고 v2.0 자료를 명확히 구분된 추가분으로 삽입한다는 결정은 인간 저자의 것이다.

전체 편집 방향. 본 제안을 철학적 에세이가 아니라 개발자용 연구 프로토콜로 구성하기로 한 결정, 본 격적인 연구 설계서가 아니라 입장 보고서로 범위를 한정하기로 한 결정, 경험적 검증 가능성을 핵심 약속으로 유지하기로 한 결정, 그리고 다른 모델과 연구자에 의한 후속 반복을

명시적으로 초청하기로 한 결정은, 모두 인간 저자의 편집 방향에 따른 것이다.

본 명시문은 재현가능성, 적절한 출처 표기, 그리고 지속적 반복을 지원하기 위해 제공된다. 본 문서는 작업 중인 문서로 의도되었으며, 추가 개정은 예상되고 또 환영된다.